

cadeias de Markov

- $p_{t+1}(x_{t+1}) = \sum_{x_1, \dots, x_t, x_{t+2}, \dots, x_N} p_N(x_1, x_2, \dots, x_N)$
- $p_{t+1}(x_{t+1}) = \sum_{x_t \in \mathcal{X}} p_t(x_t) w(x_t \rightarrow x_{t+1})$
- notação vetorial e matricial
 - \vec{p}_t = vetor coluna com elementos $p_t(a_1), p_t(a_2), \dots, p_t(a_M)$ com $\mathcal{X} = \{a_1, \dots, a_M\}$
 - $\Pi_{y,x} = w(x \rightarrow y)$ com $x \in \mathcal{X}$ e $y \in \mathcal{X}$ é a matriz de Markov
 - $\vec{p}_{t+1} = \Pi \vec{p}_t = \Pi^t \vec{p}_1$.
 - distribuição estacionária, $\vec{p}^* = \lim_{t \rightarrow \infty} \vec{p}_t$
 - $\vec{p}^* = \Pi \vec{p}^*$, e \vec{p}^* é um vetor próprio à direita de Π
com valor próprio 1

Exemplo:

ver exercicio 11

Duas caixas e N partículas

Em cada passo uma partícula é escolhida ao acaso e mudada de caixa

O número de partículas numa caixa, $0 \leq n \leq N$, é uma cadeia de Markov

$n \longrightarrow n-1$ ou $n \longrightarrow n+1$

Constroi a matriz $\hat{\Pi}$

correlação e informação mútua

definições

- Entropia conjunta.

$$S_{X,Y} = - \sum_{x,y \in \mathcal{X}} p_{X,Y}(x,y) \log_2 p_{X,Y}(x,y)$$

$$p_{xy}(x,y) = p_X(x) p_{Y|X}(y|x)$$

- Entropia condicional

$$S_{Y|X} = - \sum_{x,y \in \mathcal{X}} p_X(x) p_{Y|X}(y|x) \log_2 p_{Y|X}(y|x)$$

- Regra da cadeia

$$S_{X,Y} = S_X + S_{Y|X}$$

- Informação mútua, $I_{X,Y}$ mede a redução na incerteza em X pelo conhecimento de Y e é simétrico em X e Y. Temos

$$I_{X,Y} = \sum_{x,y \in \mathcal{X}} p_{X,Y}(x,y) \log_2 \frac{p_{X,Y}(x,y)}{p_X(x)p_Y(y)}, \quad I_{X,Y} \geq 0 \text{ e } I_{X,Y} = 0 \text{ se}$$

e só se X e Y são independentes.

$$I_{X,Y} = S_Y - S_{Y|X} = S_X - S_{X|Y}$$

Entropia Conjunta

Exercicio 14

Formula de Bayes

$$p_{xy}(x,y) = p_x(x) p_{y|x}(y|x)$$

$$S_{x,y} = - \sum_{x,y} p_{x,y}(x,y) \log p_{x,y}(x,y)$$

$$S_{x,y} = - \sum_{x,y} p_x(x) p_{y|x}(y|x) \log [p_x(x) p_{y|x}(y|x)]$$

$$S_{y,x} = - \sum_{x,y} p_x(x) p_{y|x}(y|x) \log (p_{y|x}(y|x))$$

$S_{y|x}$

$$\sum_y p_{y|x}(y|x) = 1$$

$$- \sum_{x,y} p_x(x) p_{y|x}(y|x) \log p_x(x)$$

Então

$$-\sum_{x,y} p_x(x) p_{y|x}(y|x) \log p_x(x) = S_x$$

Portanto

$$S_{y,x} = S_x + S_{y|x}$$

ou

$$S_{y,x} = S_y + S_{x|y}$$

Informação mútua

definição

$$I_{x,y} = \sum_{x,y} p_{x,y}(x,y) \log \left[\frac{p_{x,y}(x,y)}{p_x(x) p_y(y)} \right]$$

$$I_{x,y} = -S_{y|x} + S_x + S_y = -S_{y|x} + S_y$$

$$I_{x,y} = -S_{x|y} + S_x + S_y = -S_{x|y} + S_x$$

Informação mútua condicional

Exercício 15

definições

$$I_{x,y|z} = \sum_{z,x,y} p(z) p(x,y|z) \log \frac{p(x,y|z)}{p(x|z) p(y|z)}$$

$$p(x,y,z) = p(z) p(x,y|z)$$

$$p(y|x,z) = p(y|z, y|x)$$

$$I_{x,y,z} = \sum_{z,x,y} p(x,y,z) \log \frac{p(x,y,z)}{p_x(x) p_{yz}(y,z)}$$

definições

$$p(x,y,z) = p_{xz}(x,z) p(y|x,z) = p_{xz}(x,z) p(y|z, y|x)$$

$$p(y|z, y|x) = \frac{p(y|z, x)}{p(x|z)}$$

$$p_{x,y,z}(x,y,z) = p_{x,z}(x,z) \frac{p(y|z,x)}{p(x|z)}$$

$$p_{y,z}(y,z) = p_{y|z}(y|z) p_z(z)$$

$$I = \sum_{z,y} p_{x,y,z}(x,y,z) \log \frac{p_{x,y,z}(x,y,z)}{p_x(x) p_{y,z}(y,z)}$$

$$I = \sum_{z,y} p_{x,y,z}(x,y,z) \log \left[\frac{p_{x,z}(x,z)}{p_x(x)} \frac{p(y|z,x)}{p(x|z) p_{y|z}(y|z) p_z(z)} \right]$$

$$I_{x,y,z} = I_{x,z} + I_{x,y|z}$$

Regra da cadeia para
Informação Mútua

taxa de entropia

$$X_{t-1} \rightarrow X_t \rightarrow X_{t+1}$$

- para uma cadeia de Markov em que $X \rightarrow Y \rightarrow Z$ estão ordenados temporalmente $I_{X,Z} \leq I_{X,Y}$

Exercício 15

- demonstração: $I_{X,(YZ)} = I_{X,Z} + I_{X,Y|Z} = I_{X,Y} + I_{X,Z|Y}$ como $I_{X,Z|Y} = 0$ devido a que X e Z são independentes dado Y e $I_{X,Y|Z} \geq 0$ temos $I_{X,Z} \leq I_{X,Y}$

"0"

$$I_{X,Z} = I_{X,Y} - I_{X,Y|Z} \stackrel{>0}{\leq} I_{X,Y}$$

- dada a sequência, $\underline{X}_N = \{X_t\}$, $t = 1, \dots, N$ define-se a taxa de entropia como $h_{\underline{X}} = \lim_{N \rightarrow \infty} S_{\underline{X}_N}/N$
- para uma cadeia de Markov em que existe uma distribuição de probabilidade estacionária $p^*(x) = \lim_{N \rightarrow \infty} p_N^*(x)$ mostra-se que:

$$h_{\underline{X}} = - \sum_{x,y \in \mathcal{X}} p^*(x) w(x \rightarrow y) \log w(x \rightarrow y)$$

compressão de dados

- definição do problema
- dada uma sequência de variáveis aleatórias ,
 $\underline{X} = \{X_1, X_2, \dots, X_N\}$ com $X_i \in \mathcal{X}$ pretende-se armazenar informação de uma realização $\underline{x} = \{x_1, x_2, \dots, x_N\}$ da forma mais compacta possível.
- codificação
 - define-se um mapeamento w entre cada possível sequência em \mathcal{X}^N numa string binária de tamanho arbitrário $\{0,1\}^*$,
 $\underline{x} \mapsto w(\underline{x})$
- compressão de uma sequência
 - uma sequência grande (stream) é partida em blocos de tamanho N
 - cada bloco é codificado com w
 - as palavras de código são concatenadas para formar uma sequência codificada mais compacta

compressão de dados

Example 1.14 Take $N = 1$, and consider a random variable X which takes values in $\mathcal{X} = \{1, 2, \dots, 8\}$ with probabilities $p(1) = 1/2$, $p(2) = 1/4$, $p(3) = 1/8$, $p(4) = 1/16$, $p(5) = 1/32$, $p(6) = 1/64$, $p(7) = 1/128$, and $p(8) = 1/128$. Consider the two codes w_1 and w_2 defined by the table below:

x	$p(x)$	$w_1(x)$	$w_2(x)$	
1	1/2	000	0	
2	1/4	001	10	
3	1/8	010	110	
4	1/16	011	1110	
5	1/32	100	11110	(1.31)
6	1/64	101	111110	
7	1/128	110	1111110	
8	1/128	111	11111110	

These two codes are instantaneous. For instance, looking at the code w_2 , the encoded string 10001101110010 can be parsed in only one way, since each symbol 0 ends a codeword. It thus corresponds to the sequence $x_1 = 2, x_2 = 1, x_3 = 1, x_4 = 3, x_5 = 4, x_6 = 1, x_7 = 2$. The average length of code w_1 is $L(w_1) = 3$, and the average length of code w_2 is $L(w_2) = 247/128$. Notice that w_2 achieves a shorter average length because it assigns the shortest codeword (namely 0) to the most probable symbol (i.e. $x = 1$).

000 e 0000 não poderiam ser simultaneamente palavras de código porque 000 é a string inicial de 0000




Figure: códigos de decodificação única. Nenhuma palavra de código é antecessora de outra palavra de código.

teorema da compressão ótima

$p_x(x)$ = probabilidade do carácter x no texto (fonte)

$$S_x = - \sum_x p_x(x) \log p_x(x)$$

- comprimento médio do código

$$L(w) = \sum_{\underline{x} \in \mathcal{X}^N} p(\underline{x}) l_w(\underline{x})$$

$l_w(\underline{x})$ = comprimento do código de \underline{x}

- Teorema da compressão ótima

Shannon

- Seja L_N^* o comprimento ótimo de um código para a sequência

$\underline{X} = \{X_1, X_2, \dots, X_N\}$ com entropia $S_{\underline{X}}$

(1) para qualquer $N \geq 1$ temos $S_{\underline{X}} \leq L_N^* \leq S_{\underline{X}} + 1$

(2) se a fonte tiver uma taxa de entropia finita, $h = \lim_{N \rightarrow \infty} S_{\underline{X}}/N$

então $\lim_{N \rightarrow \infty} L_N^*/N = h$

teorema da compressão ótima


- Consideremos um código binário instantâneo. Seja L_M o comprimento da palavra de código maior. Para cada palavra de código de comprimento $l_w(\underline{x})$ o número de descendentes de comprimento L_M não usados é $2^{L_M - l_w(\underline{x})}$. O número total de códigos não usados no nível L_M é $\sum_{\underline{x} \in \mathcal{X}^N} 2^{L_M - l_w(\underline{x})}$. Este número tem que ser inferior ao número total possível com L_M bits, 2^{L_M} , ou seja $\sum_{\underline{x} \in \mathcal{X}^N} 2^{-l_w(\underline{x})} \leq 1$.

Dado x

$$l_w(x) = 2$$

código de $x \rightarrow 000$

$$L_m = 4$$



Há 4 códigos no nível $L_m = 4$

que não podem ser usados
por se ter usado 000

$$2^{L_m - l_w(x)} = 4$$

teorema da compressão ótima

- Para dados com distribuição $p_{\underline{X}}(\underline{x})$ o comprimento médio é $L = \sum_{\underline{x} \in \mathcal{X}^{\mathcal{N}}} p_{\underline{X}}(\underline{x}) l_w(\underline{x})$. Pode minimizar-se L com a restrição

$$\sum_{\underline{x} \in \mathcal{X}^{\mathcal{N}}} 2^{-l_w(\underline{x})} = a \leq 1. \text{ Ou seja:}$$

$$\frac{\partial}{\partial l_w(\underline{x})} \left[\sum_{\underline{x} \in \mathcal{X}^{\mathcal{N}}} p_{\underline{X}}(\underline{x}) l_w(\underline{x}) + \beta \left(\sum_{\underline{x} \in \mathcal{X}^{\mathcal{N}}} 2^{-l_w(\underline{x})} - a \right) \right] = 0$$

multiplicador de Lagrange
minimização com restrição

$$\frac{\partial}{\partial l_w(\underline{x})} \sum_{\underline{x}} p_{\underline{x}}(\underline{x}) l_w(\underline{x}) = p_{\underline{x}}(\underline{x})$$

$$\begin{aligned} \frac{\partial}{\partial l_w(\underline{x})} 2^{-l_w(\underline{x})} &= \frac{\partial}{\partial l_w(\underline{x})} e^{-\ln 2 l_w(\underline{x})} = \\ &= -\ln 2 e^{-\ln 2 l_w(\underline{x})} \\ &= -\ln 2 2^{-l_w(\underline{x})} \end{aligned}$$

$$p_{\underline{x}}(\underline{x}) - \beta \ln 2 2^{-l_w(\underline{x})} = 0$$

teorema da compressão ótima


- Obtém-se $p_{\underline{X}}(\underline{x}) - \beta \ln 2 2^{-l_w(\underline{x})} = 0$. Como $\sum_{\underline{x} \in \mathcal{X}^N} p_{\underline{X}}(\underline{x}) = 1$ temos $\beta \ln 2 = \frac{1}{a}$ e $l_w(\underline{x}) = -\log_2 \frac{p_{\underline{X}}(\underline{x})}{a}$. Como $a \leq 1$ o menor $l_w^*(\underline{x})$ consegue-se com $a = 1$ e $l_w^*(\underline{x}) = -\log_2 p_{\underline{X}}(\underline{x})$. Então $L^* = - \sum_{\underline{x} \in \mathcal{X}^N} p_{\underline{X}}(\underline{x}) \log_2 p_{\underline{X}}(\underline{x}) = S_{\underline{X}}$. Como L^* é inteiro temos $S_{\underline{X}} \leq L^* \leq S_{\underline{X}} + 1$. o comprimento médio do código ótimo é igual à entropia da fonte
- Dividindo por N e tomando o limite $N \rightarrow \infty$ temos
$$h \leq \lim_{N \rightarrow \infty} \frac{L^*}{N} \leq h, \text{ com } h \text{ a taxa de entropia, } h = \lim_{N \rightarrow \infty} \frac{S_{\underline{X}}}{N}$$

A entropia da fonte de informação determina a compressão máxima possível

algoritmo de Huffman

Para encontrar um código instantâneo ótimo.

- Dado um vetor de probabilidade, $p_X(x)$ dos caracteres do alfabeto, \mathcal{X}
 - repetir até \mathcal{X} ter 1 elemento
 - remover os dois caracteres de probabilidade mais baixa do alfabeto, c_{i_1} e c_{i_2} criando o alfabeto $\mathcal{X} = \mathcal{X} \setminus \{c_{i_1}, c_{i_2}\}$.
 - adicionar ao alfabeto um caracter c_p , $\mathcal{X} = \{\mathcal{X}, c_p\}$, ...
atribuindo a probabilidade, $p_X(c_p) = p_X(c_{i_1}) + p_X(c_{i_2})$
 - os dois caracteres removidos são os filhos 1 e 2 de c_p
- seguir a árvore binária desde a raiz atribuindo ao Filho 1 bit 0 e Filho 2 bit 1. Os nodos sem filhos são as palavras de código do alfabeto original \mathcal{X}



canais de comunicação




Fig. 1.3 Typical flowchart of a communication device.




Fig. 1.4 Three communication channels. *Left*: the binary symmetric channel. An error in the transmission, in which the output bit is the opposite of the input one, occurs with probability p . *Middle*: the binary erasure channel. An error in the transmission, signaled by the output $*$, occurs with probability ϵ . *Right*: the Z channel. An error occurs with probability p whenever a 1 is transmitted.

Figure: canais binários de comunicação

- mensagem codificada $\underline{x} = (x_1, x_2, \dots, x_N)$, with N bits
- mensagem recebida $\underline{y} = (y_1, y_2, \dots, y_N)$, (Binary Channel)

Canais de comunicação

- canal sem memória $Q(\underline{y}|\underline{x}) = \prod_{i=1, \dots, N} Q(y_i|x_i)$
 - capacidade do canal, $C = \max_{p(x)} I_{X,Y}$ com $p(x)$ = distribuição de probabilidade da fonte
- $$I_{X,Y} = \sum_{x \in \mathcal{X}} \sum_{y \in \mathcal{Y}} p(x,y) \log_2 \frac{p(x,y)}{p(x)p(y)} \text{ e } p(x,y) = p(x)Q(y|x)$$
- $C=0$ se X e Y não estão correlacionados $p(x,y) = p(x)p(y)$ e se $p(x,y) = p(x)\delta_{y,x}$, $C = 1$

$0 \leq C \leq 1$ caracteriza a "qualidade" do canal de comunicação

Uma maior correlação entre a mensagem recebida e a mensagem codificada enviada significa maior capacidade

Códigos de correção de erros

- mensagem original $\underline{m} = (m_1, m_2, \dots, m_M)$, M bits (*Block*)
- mensagem codificada $\underline{x}(\underline{m}) = (x_1, x_2, \dots, x_N)$, $N \geq M$
- mensagem recebida $\underline{y} = (y_1, y_2, \dots, y_N)$
- mensagem decodificada $\underline{m}' = d(\underline{y})$
- Taxa do código: $R = \frac{M}{N}$ (preferencialmente a maior possível) $0 \leq R \leq 1$
- Probabilidade de erro (no *Block* \underline{m}):
$$P_B(\underline{m}) = \sum_{\underline{y}} Q(\underline{y} | \underline{x}(\underline{m})) I(d(\underline{y}) \neq \underline{m})$$
- Prob. erro média: $P_B^{av} = \frac{1}{2^M} \sum_{\underline{m}} P_B(\underline{m})$