



Modelo SIR e tempos longos

- No modelo SIR para além da transmissão há recuperação a uma taxa γ
- Começa-se com um infetado na GC
- Se assumirmos que todos os infetados recuperam num tempo $\tau = \frac{1}{\gamma}$ fixo não aleatório.
Existe uma probabilidade de um infetado não transmitir (por recuperar antes) = $\lim_{dt \rightarrow 0} (1 - \beta dt)^{\frac{\tau}{dt}} = e^{-\beta\tau} = 1 - \phi$
e uma probabilidade de transmissão através de uma aresta dada por $\phi = 1 - e^{-\beta\tau}$.
- Para tempos longos tudo se passa como se a transmissão não ocorresse, em cada aresta, com probabilidade $1 - \phi$ e podemos remover essa aresta, com esta probabilidade.

Rede com componente gigante



Percolação- é um modelo do ataque a uma rede removendo arestas e/ou vértices



com probabilidade $1 - \phi$
removemos arestas

existe um ϕ_c (phi critico)

tal que para $\phi < \phi_c$ deixa

de existir componente gigante

Transição epidémica e percolação

- A transição epidémica é uma transição de percolação
Se ϕ for baixo não há GC e não se estabelece uma epidemia.
- u = probabilidade do vértice não contagiar através de uma aresta
 $\phi \sum_k q_k u^k$ = probabilidade de transmitir ao vizinho mas este não propagar a epidemia
 nã trashmitiu trashmitiu mas não propagou
- $u = 1 - \phi + \phi \sum_k q_k u^k = 1 - \phi + \phi g_1(u)$, u^k = probabilidade do vértice não transmitir a qualquer vizinho
 $\frac{d}{du} [1 - \phi_c + \phi_c g_1(u)]|_{u=1} = 1$ temos $\phi_c = \frac{1}{g_1'(1)}$
 Se $\phi < \phi_c$ só há uma solução: $u = 1$
 Se $\phi > \phi_c$ há uma solução: $u < 1$

Tamanho da epidemia

- $S = 1 - \sum_k u^k p_k = 1 - g_0(u)$ é a fracção média de vértices infetados
 $S = 0$ se $\phi < \phi_c$ e $S \neq 0$ se $\phi > \phi_c$
- $\phi_c = 1 - e^{-R_0 \cdot c} = \frac{\langle k \rangle}{\langle k^2 \rangle - \langle k \rangle}$ com $R_0 = \frac{\beta}{\gamma}$
- Para uma rede aleatória com distribuição de grau Poisson
 $\langle k^2 \rangle - \langle k \rangle^2 = \langle k \rangle$
 $\phi_c = \frac{1}{\langle k \rangle} = \frac{1}{c}$ e $R_{0,c} = \ln \frac{c}{c-1}$
 $S = 1 - e^{-c\phi S}$
- Vacinação corresponde a remover vértices

$$c_{eff} = c\phi$$

$$c_{eff,c} = c\phi_c = 1 \Rightarrow \phi_c = \frac{1}{c}$$

Epidemias em redes complexas

- distribuição de grau \longrightarrow rede complexa
 $p_k \sim \frac{1}{k^\alpha}$, $2 < \alpha < \infty$
- Se $2 < \alpha < 3$ temos $\{\langle k^2 \rangle = \infty\}$ e $\phi_c = 0$. A epidemia existe sempre! É impossível fazer parar a epidemia.
- Existem Hubs ou seja vértices com elevado número de arestas. Só removendo esses Hubs podemos parar a epidemia.

Dependência temporal para o modelo SIR

- Equações da dinâmica: $\frac{ds_i}{dt} = -\beta s_i \sum_j A_{ij} x_j$;
 $\frac{dx_i}{dt} = \beta s_i \sum_j A_{ij} x_j - \gamma x_i$; $\frac{dr_i}{dt} = \gamma x_i$;
 $s_0 = 1 - 1/n$ $x_0 = 1/n$

- Tempos curtos

Equações linearizadas (Aproximação)

$$\frac{d\bar{x}}{dt} = \beta \bar{M} \bar{x}, \text{ com } \bar{M} = \bar{A} - \frac{\gamma}{\beta} \bar{I}. \text{ com } \bar{I} = \text{matriz identidade}$$

$$x(t) \sim a_1(0) e^{(\beta \kappa_1 - \gamma)t} \text{ com } \kappa_1 \text{ o maior valor próprio de } \bar{A}$$

Transição de fase epidémica

$$R_{0.c} = \left(\frac{\beta}{\gamma} \right)_c = \frac{1}{\kappa_1}$$

Aproximação baseada no grau para SIR

- Equações da dinâmica:

$$\frac{ds_k}{dt} = -\beta k s_k v(t); \frac{dx_k}{dt} = \beta k s_k v(t) - \gamma x_k; \frac{dr_k}{dt} = \gamma x_k$$

$$\text{Definindo } v(t) = \sum_{k=0}^{\infty} q_k x_k \text{ e } w(t) = \sum_{k=0}^{\infty} q_k r_k(t),$$

$$\text{Obtém-se } s_k = s_0 e^{-\frac{\beta}{\gamma} k w(t)}, \text{ Define-se } u(t) = \exp(-\frac{\beta}{\gamma} w)$$

$$\text{Obtém-se, } s_k(t) = s_0 u^k$$

- $v(t) = \sum_{k=0}^{\infty} q_k x_k = \sum_{k=0}^{\infty} q_k (1 - s_k - r_k) =$
 $1 - w(t) - s_0 g_1(u) = 1 + \frac{\gamma}{\beta} \ln u - s_0 g_1(u)$

- $\frac{dw}{dt} = \sum_k q_k \frac{dr_k}{dt} = \sum_k \gamma q_k x_k = \gamma v$

- $\frac{du}{dt} = -\frac{\beta}{\gamma} u \frac{dw}{dt} = -\beta u \left[1 + \frac{\gamma}{\beta} \ln u - s_0 g_1(u) \right]$, resolve-se para $u(t)$

- $s(t) = \sum_k s_k p_k = s_0 g_0(u)$

gráficos para o modelo SIR

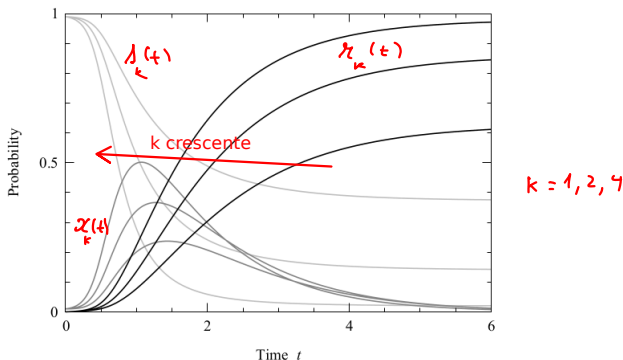


Figure: s_k , x_k e r_k par o modelo SIR para $\beta = \gamma = 1$ para $k=1, 2$ e 4 para uma rede com distribuição e grau exponencial com parâmetro $\lambda = 0.1$. (do livro de Newman)

transição epidémica

- Obtém-se na aproximação baseada no grau para
$$R_{0.c} = \left(\frac{\beta}{\gamma}\right)_c = \frac{1}{g'_1(1)}$$
- Não concorda completamente com o resultado anteriormente obtido $\phi_c = 1 - e^{-R_{0.c}} = \frac{1}{g'_1(1)}$ para o modelo SIS quando cada infetado recupera no tempo exatamente $\tau = \frac{1}{\gamma}$ a não ser quando $R_{0.c} \ll 1$

Modelação e Física Estatística

Método de Monte Carlo em tempo contínuo

António Luís Ferreira

June 1, 2021

Temas

- 1 equação mestra
- 2 distribuição do tempo de espera
- 3 algoritmo

equação mestra

- tempo discreto $P(x, t + \Delta t) = \sum_{x'} \Pi_{x,x'} P(x', t)$. com
 $\Pi_{x,x'} = W(x' \rightarrow x) \Delta t$ se $x' \neq x$ e
 $\Pi_{x,x} = 1 - \sum_{x' \neq x} W(x \rightarrow x') \Delta t$ onde $W(x' \rightarrow x)$ é a taxa de transição do estado x' para x .

$$P(x, t + \Delta t) - P(x, t) = \sum_{x'} [\Pi_{x,x'} P(x', t) - \Pi_{x',x} P(x, t)]$$

dado que $\sum_{x'} \Pi_{x',x} = 1$

$$\begin{aligned} \frac{dP(x,t)}{dt} &= \frac{P(x, t + \Delta t) - P(x, t)}{\Delta t} \\ &= \sum_{x' \neq x} W(x' \rightarrow x) P(x', t) - P(x, t) \sum_{x' \neq x} W(x \rightarrow x') \end{aligned}$$

distribuição do tempo de espera

- a distribuição do tempo de espera, τ , num estado x pode ser obtida de

$$P_W(x, \tau) \Delta t = \lim_{\substack{\Delta t \rightarrow 0 \\ n \rightarrow \infty}} \sum_{x' \neq x} P_{x', x} \prod_{x, x}^{n-1} \text{ com } \tau = n \Delta t,$$

$$P_W(x, \tau) = \lim_{n \rightarrow \infty} \sum_{x' \neq x} W(x \rightarrow x') \left(1 - \sum_{x' \neq x} W(x \rightarrow x') \frac{\tau}{n}\right)^{n-1}$$

$$P_W(x, \tau) = \lambda_x \exp(-\lambda_x \tau) \text{ com } \lambda_x = \sum_{x' \neq x} W(x \rightarrow x')$$

tempo médio de espera, $\bar{\tau}_x = \frac{1}{\lambda_x}$

algoritmo

- Dado o sistema no estado x gerar um tempo de espera com distribuição exponencial

$$\tau = \frac{1}{\lambda_x} \ln(1 - \hat{U})$$
- Escolher o estado x' para o qual o sistema transita com probabilidade $\frac{W(x \rightarrow x')}{\lambda_x}$. Esta probabilidade está normalizada dado que $\lambda_x = \sum_{x' \neq x} W(x \rightarrow x')$
- incrementar o tempo $t_i = t_{i-1} + \tau_{i-1}$ onde t_i representa o instante de tempo onde foi observada a transição entre o estado x_{i-1} e o estado x_i (com $t_0 = 0$)
- Para calcular a média em regime estacionário do observável $\mathcal{O}(x)$ fazemos: $\overline{\mathcal{O}(x)} = \frac{\sum_i \tau_i \mathcal{O}(x_i)}{\sum_i \tau_i}$

caso de número finito de classes de taxas de transição

- No caso em que as transições de qualquer x para x' têm taxas de transição que tomam um conjunto finito, N_C de valores possíveis podemos para um dado x identificar os estados x' que pertencem a cada classe de taxas.
- então $\lambda_x = \sum_{i=1}^{N_C} r_i n_i(x)$ onde r_i é a taxa da classe i e $n_i(x)$ é o número de estados x' na classe i .
- Escolhemos a classe a que pertence o estado final com probabilidade $\frac{n_i(x) r_i}{\lambda_x}$.
- Escolhemos x' , com igual probabilidade de entre os estados finais que pertencem à classe escolhida.
- atualizamos a lista dos estados em cada classe para conhecer $n_i(x')$